

ТМО РК1 Панасюк Ксения ИУ5-64Б

Вариант: 18 (Задача 3, Датасет 2)

```
In [1]: import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.datasets import load_wine
from sklearn.preprocessing import MinMaxScaler, LabelEncoder, OneHotEncoder
```

```
In [2]: wine = load_wine()
df = pd.DataFrame(data=wine.data, columns=wine.feature_names)
# Добавляем целевую переменную как основу для категорий
df['target'] = wine.target
```

```
In [3]: # Создадим признак "Alcohol_Intensity" на основе содержания алкоголя.
def define_intensity(alcohol):
    if alcohol < 12.5: return 'Low'
    elif alcohol < 13.5: return 'Medium'
    else: return 'High'

df['intensity'] = df['alcohol'].apply(define_intensity)

print("Первые 5 строк модифицированного датасета:")
display(df[['alcohol', 'intensity', 'magnesium']].head())
```

Out:

Первые 5 строк модифицированного датасета:

	alcohol	intensity	magnesium
0	14.23	High	127.0
1	13.20	Medium	100.0
2	13.16	Medium	101.0
3	14.37	High	113.0
4	13.24	Medium	118.0

```
In [4]: # А) Масштабирование данных
        scaler = MinMaxScaler()
        df['magnesium_scaled'] = scaler.fit_transform(df[['magnesium']])

        # Б) Преобразование категориальных признаков в количественные (Label Encoding)
        le = LabelEncoder()
        df['intensity_label'] = le.fit_transform(df['intensity'])

        # В) Преобразование категориальных признаков в количественные (One-Hot Encoding)
        ohe = pd.get_dummies(df['intensity'], prefix='intensity_ohe')
        df = pd.concat([df, ohe], axis=1)

        print("\nРезультаты преобразований (фрагмент):")
        display(df[['magnesium', 'magnesium_scaled', 'intensity', 'intensity_label', 'intensity_ohe_H
            igh']].head())
```


Out:

Результаты преобразований (фрагмент):

	magnesium	magnesium_scaled	intensity	intensity_label	intensity_ohe_High	intensity_ohe_High
0	127.0	0.619565	High	0	True	True
1	100.0	0.326087	Medium	2	False	False
2	101.0	0.336957	Medium	2	False	False
3	113.0	0.467391	High	0	True	True
4	118.0	0.521739	Medium	2	False	False

```
In [5]: plt.figure(figsize=(10, 6))
        sns.violinplot(x='target', y='alcohol', data=df)
        plt.title('Распределение содержания алкоголя по классам вин (Violin Plot)')
        plt.xlabel('Класс вина (Target)')
        plt.ylabel('Содержание алкоголя')
        plt.show()
```

Out:



Использованные методы

Для нормализации признака `magnesium` был применен **метод MinMaxScaler**, который перевел исходные значения в диапазон $[0, 1]$. Это необходимо для того, чтобы алгоритмы машинного обучения не придавали избыточный вес признакам с большими числовыми значениями, обеспечивая равный вклад всех параметров в итоговую модель.

Метод Label Encoding использовался для преобразования текстовых категорий интенсивности в целочисленные метки. Данный подход выбран из-за наличия логического порядка в данных, что позволяет сохранить информацию о соподчиненности значений без увеличения количества столбцов в таблице.

Для исключения ложной математической зависимости между категориями было выполнено **One-Hot кодирование**. Путем создания бинарных столбцов для каждой категории мы обеспечили корректную интерпретацию данных линейными моделями, для которых прямое использование чисел (0, 1, 2) могло бы ошибочно указывать на количественное превосходство одной категории над другой.

Была построена **скрипичная диаграмма** распределения алкоголя. Выбор этого графика обусловлен его способностью одновременно отображать ключевые статистические показатели (медиану, квантили) и плотность распределения данных, что позволяет визуально оценить компактность и симметричность признаков для каждого класса вин.